



# Bootcamp

## Inteligencia Artificial

Nivel (Intermedio)  
Docente: Víctor Viera Balanta  
Fecha 23/07/2024

UT TALENTOTECH

# Tabla de contenidos

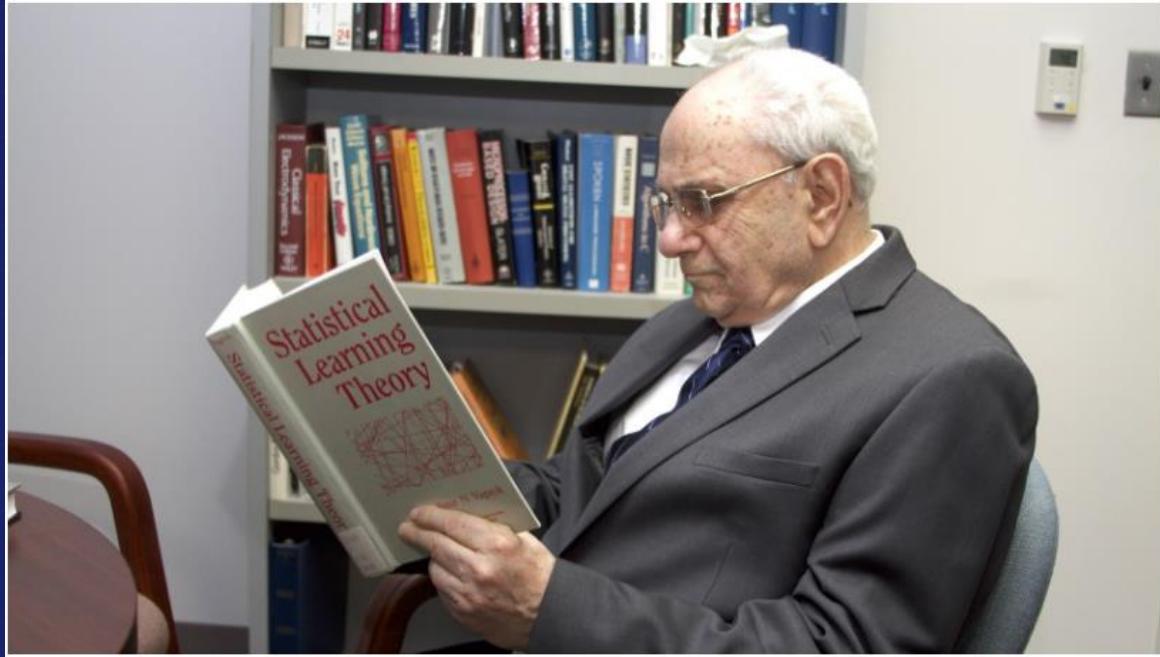
- 1
- 2
- 3
- 4

Recapitular

SVM (Support Vector Machine)

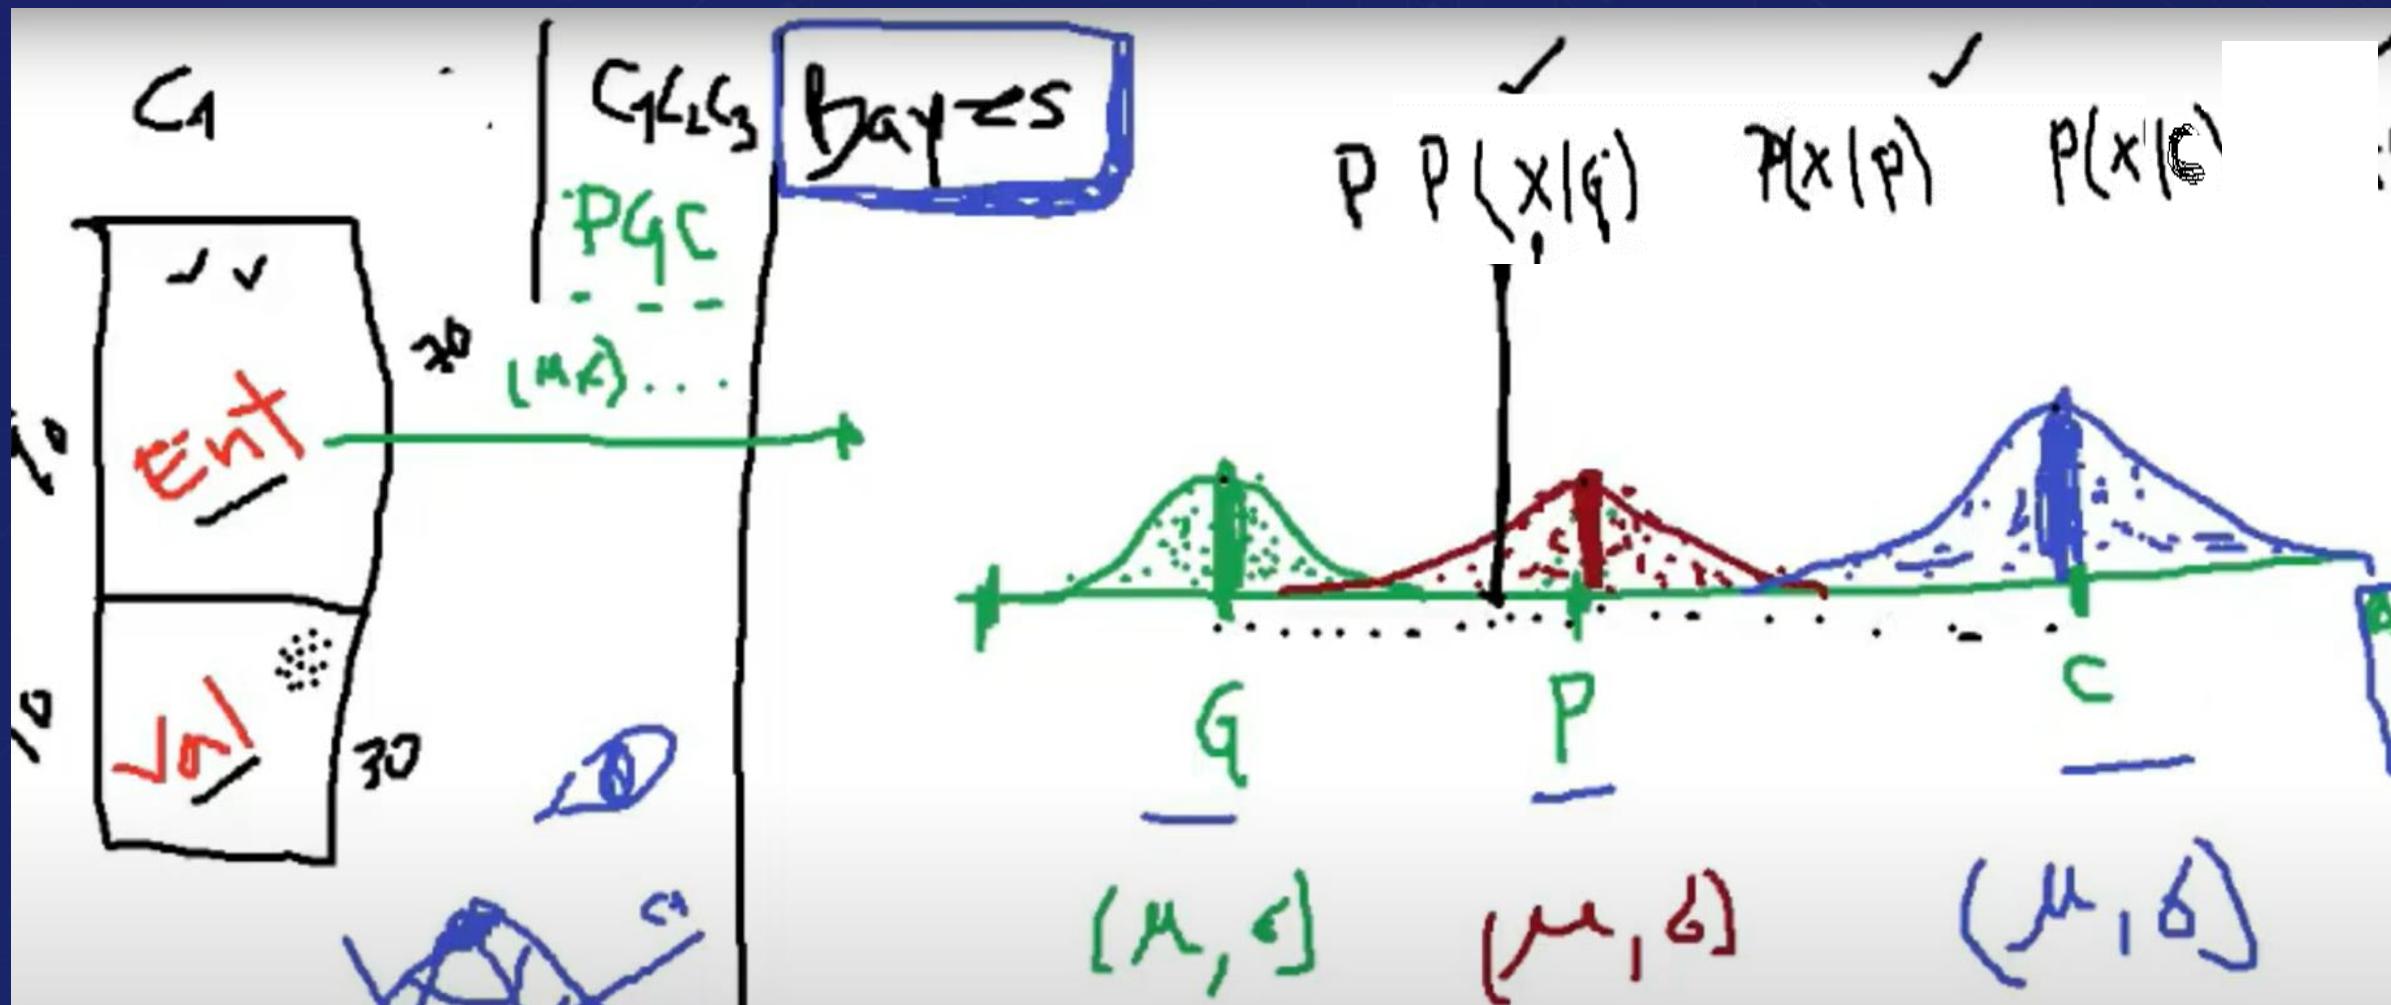
Código Fuente-Tiempo código

---

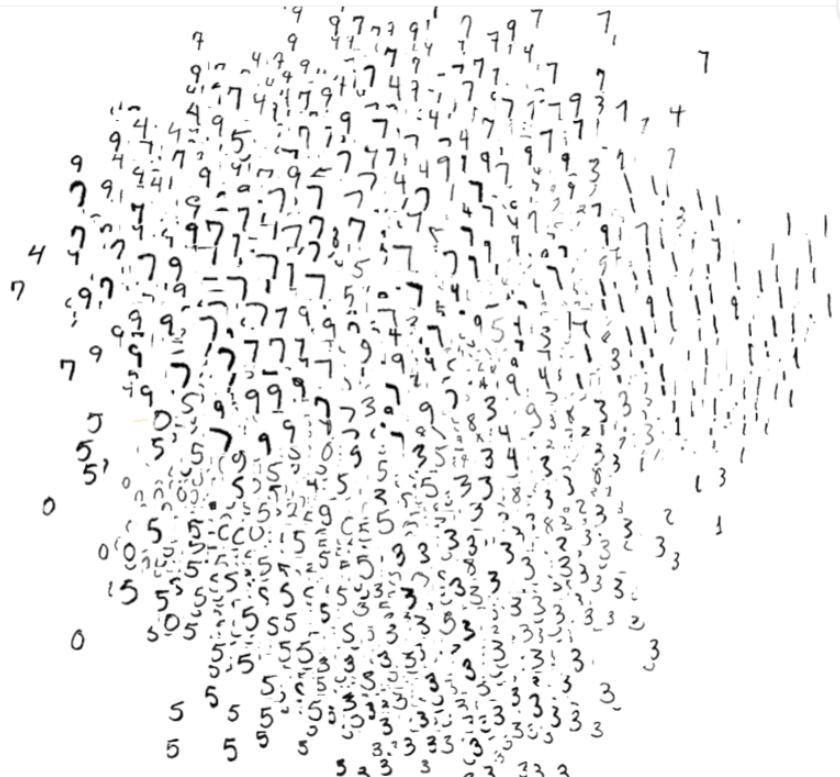


1990 desarrolla los SVM

Vladimir Vapnik



# Minist *Modified National Institute of Standards and Technology*



Creado en 1994, con imágenes de dígitos entre 0 y 9, escritos a mano.

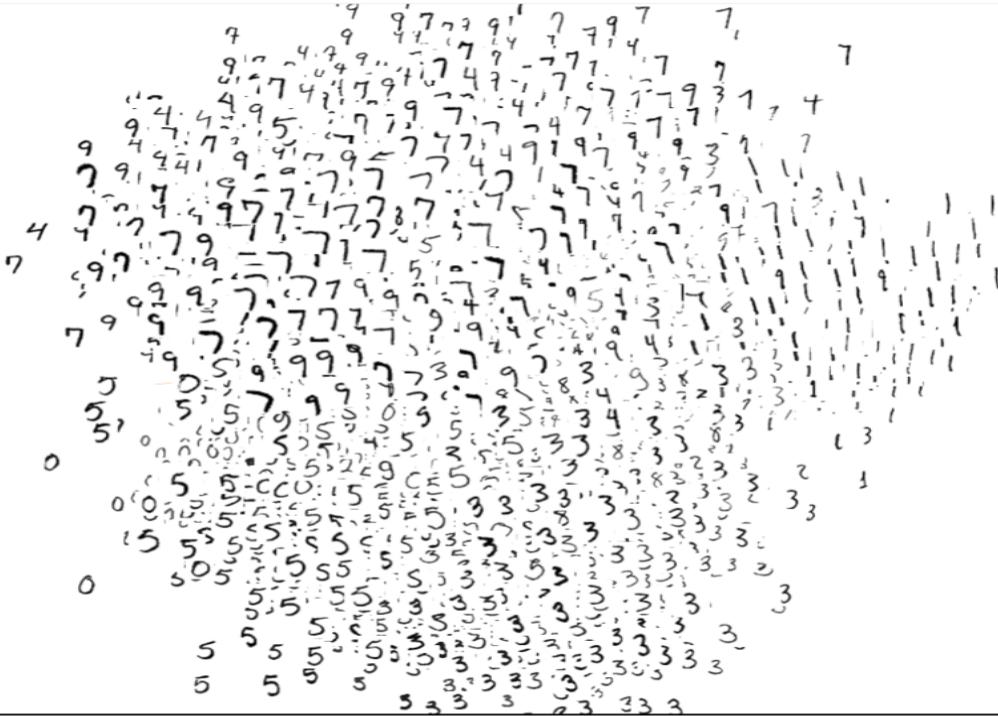
60,000 imágenes entrenamiento  
10,000 imágenes de prueba.

UT TALENTOTECH

<https://projector.tensorflow.org/>

Profesor: Víctor Viera Balanta

# Minist *Modified National Institute of Standards and Technology*



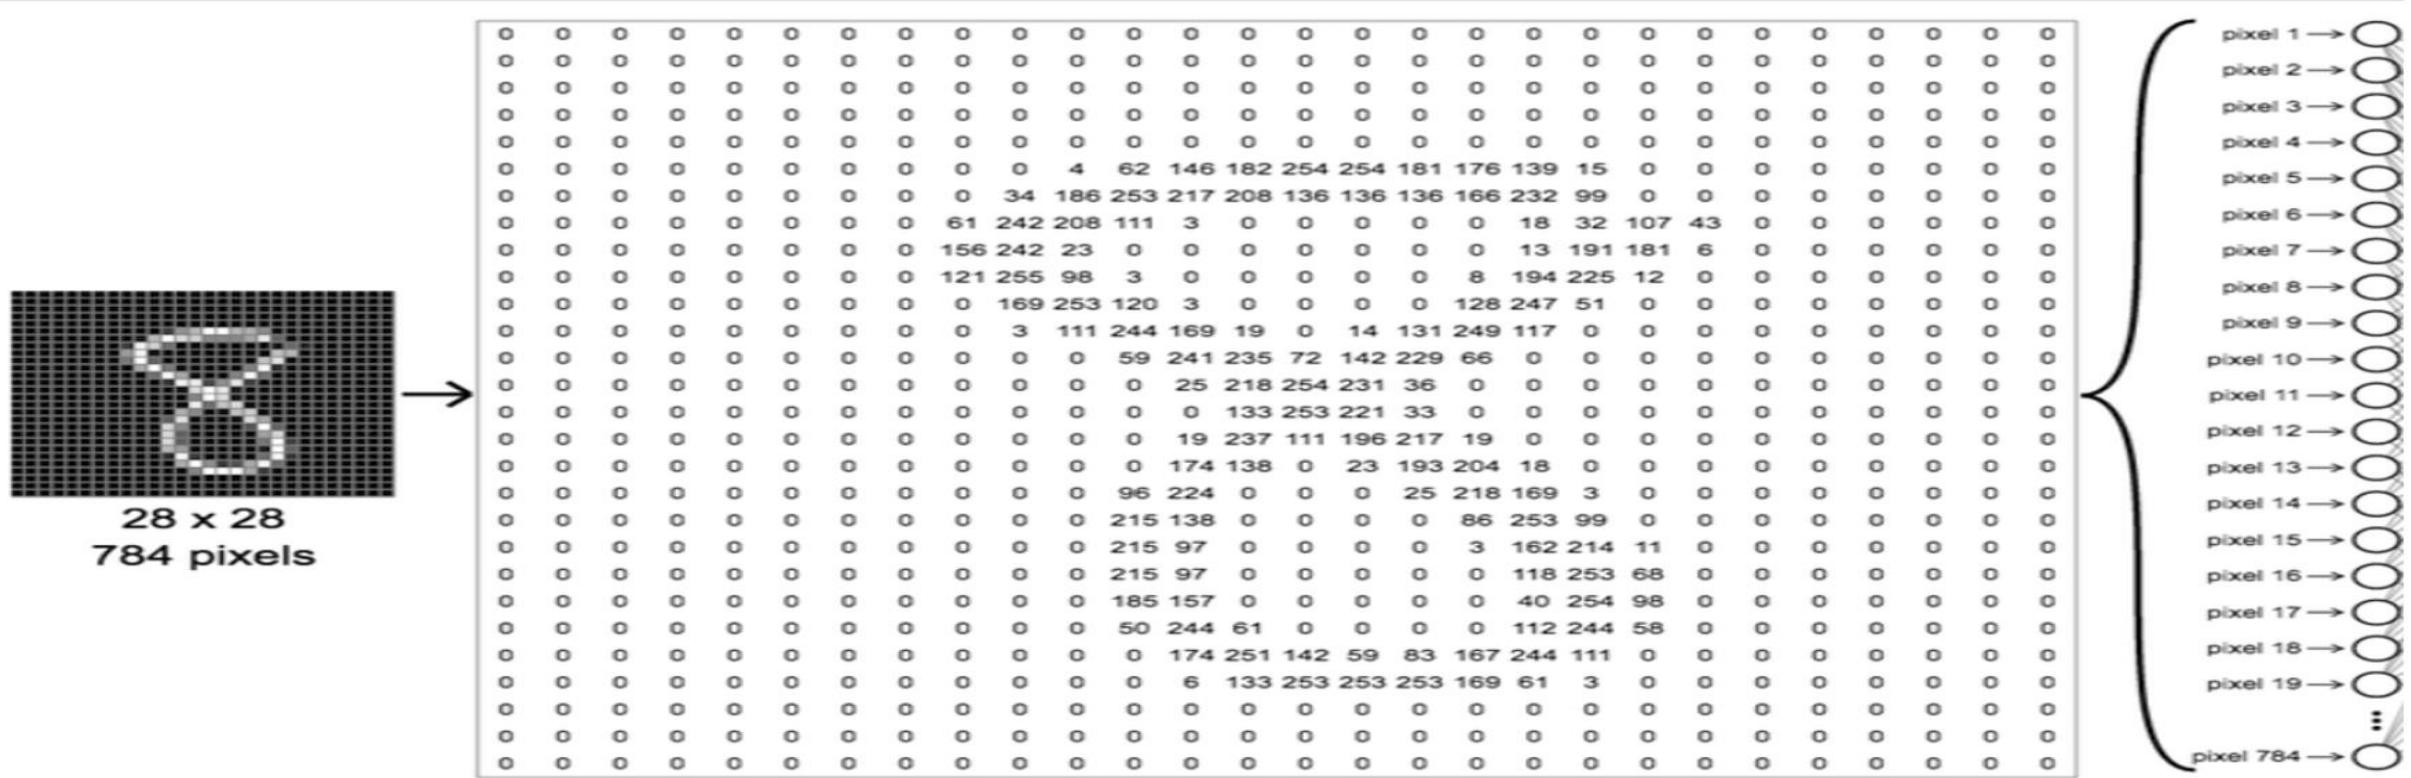
Creado en 1994, con imágenes de dígitos entre 0 y 9, escritos a mano.

60,000 imágenes entrenamiento  
10,000 imágenes de prueba.

<https://projector.tensorflow.org/>

UT TALENTOTECH

Minist *Modified National Institute of Standards and Technology*

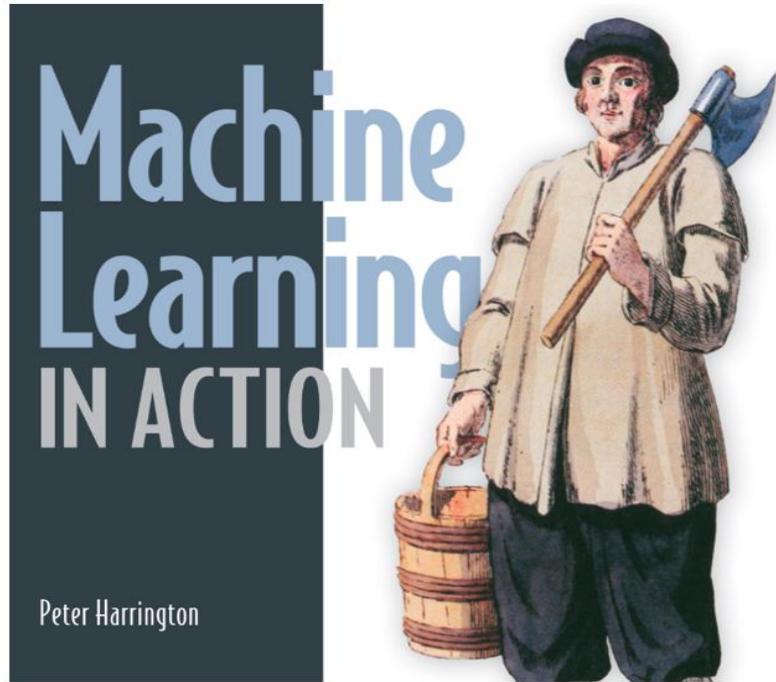


[https://ml4a.github.io/ml4a/es/neural\\_networks/](https://ml4a.github.io/ml4a/es/neural_networks/)

Víctor Viera Balanta

**Profesor: Víctor Viera Balanta**

# Máquinas de Soporte Vectorial (SVM)



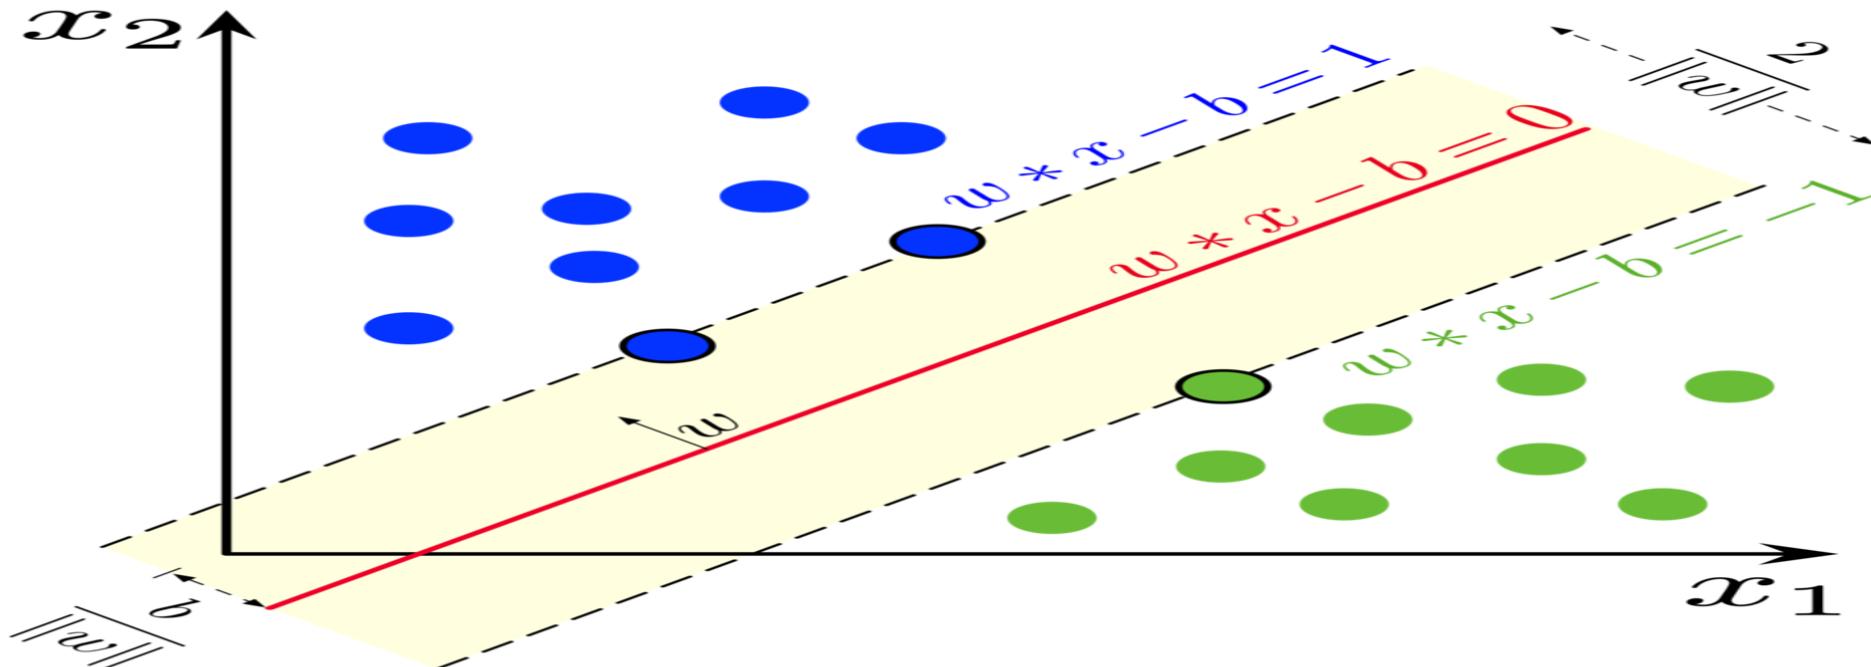
# Minist *Modified National Institute of Standards and Technology*



```
train_images = datasets.load_digits()  
train_images.data  
train_images.target
```

UT TALENTOTECH

## Máquinas de Soporte Vectorial (SVM)



Linealmente separable. Aprendizaje Supervisado

# Máquinas de Soporte Vectorial (SVM)

Algoritmos clásicos de Machine Learning.

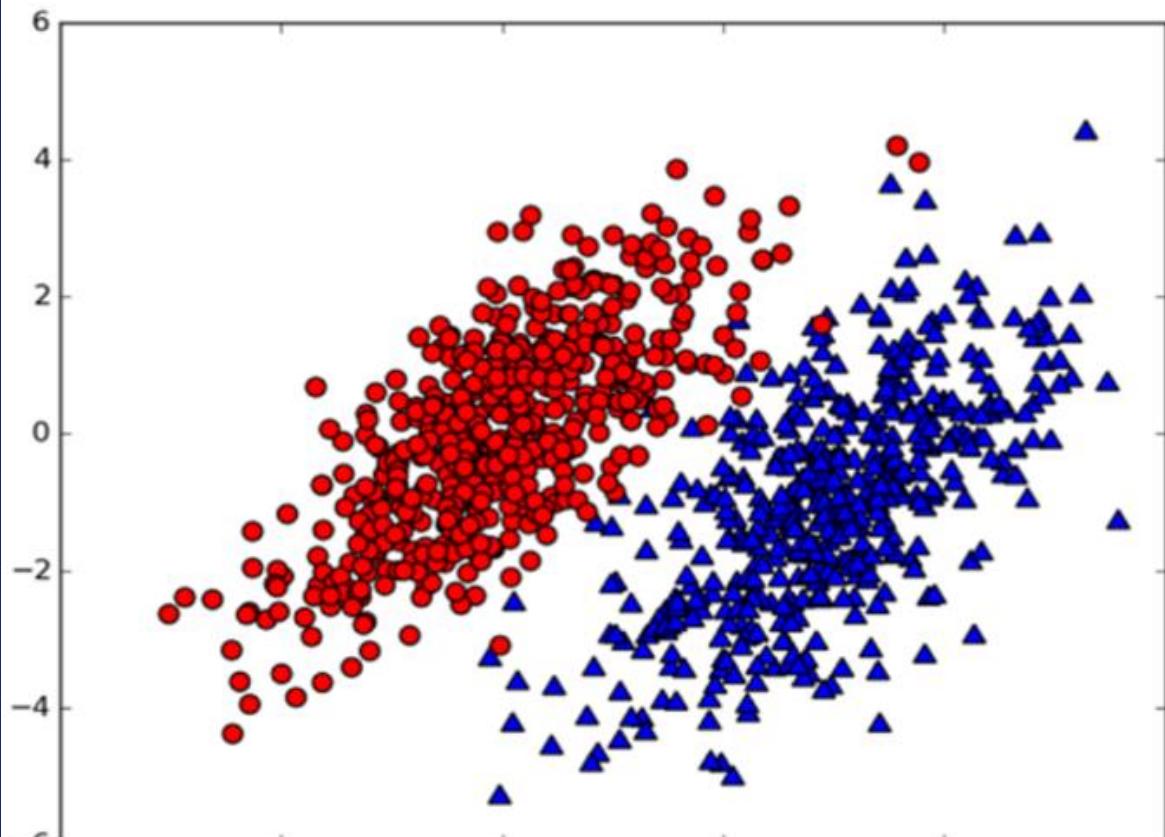
Muy usados para clasificación Binaria.

Kernelized Support Vector Machines

Tienen mecanismos de Kernel.

También se pueden usar para clasificación multiclas.

Problemas de optimización.



*Separating data with the maximum margin*

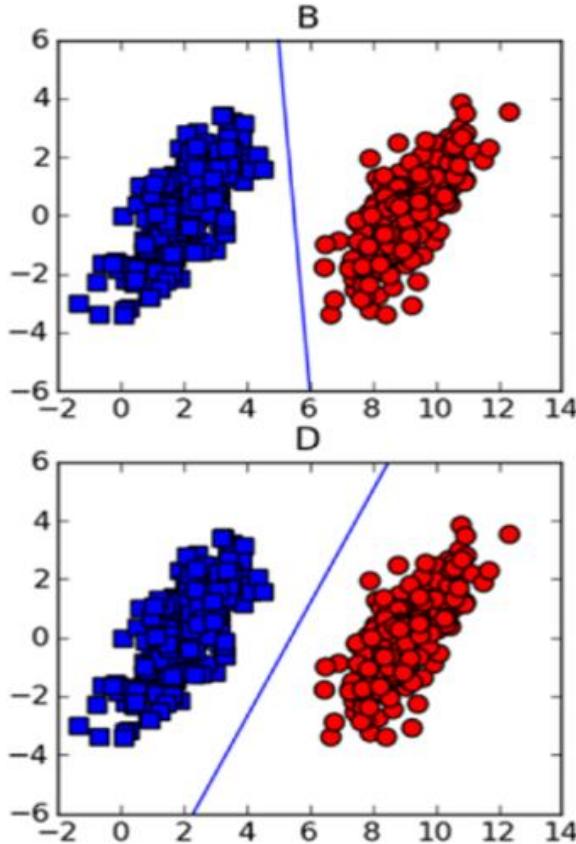
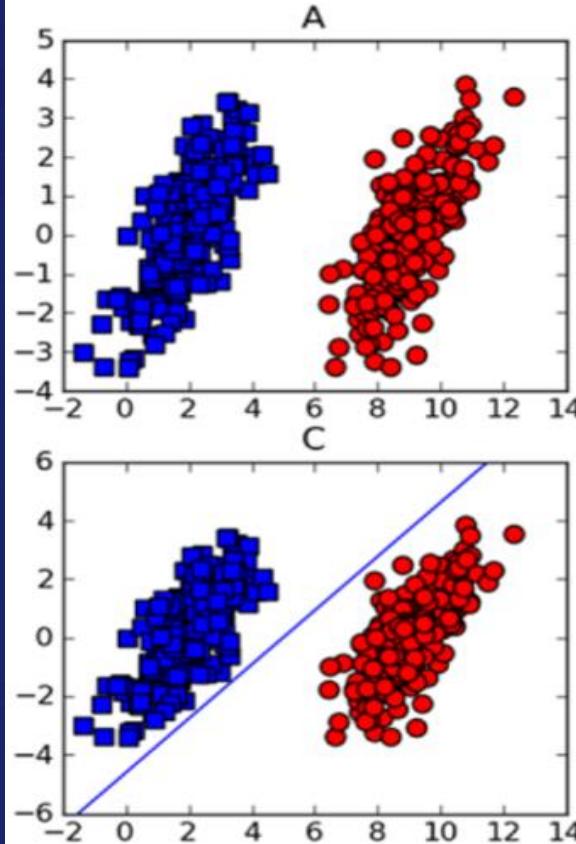
$$\{x_i, d_i\}_{i=1}^N$$

Variables independientes con dependientes

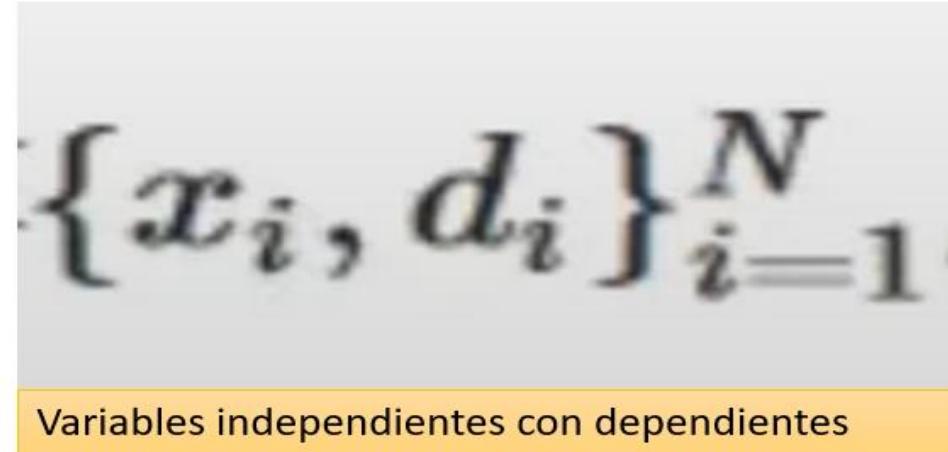


Profesor: Víctor Viera Balanta

UT TALENTOTECH

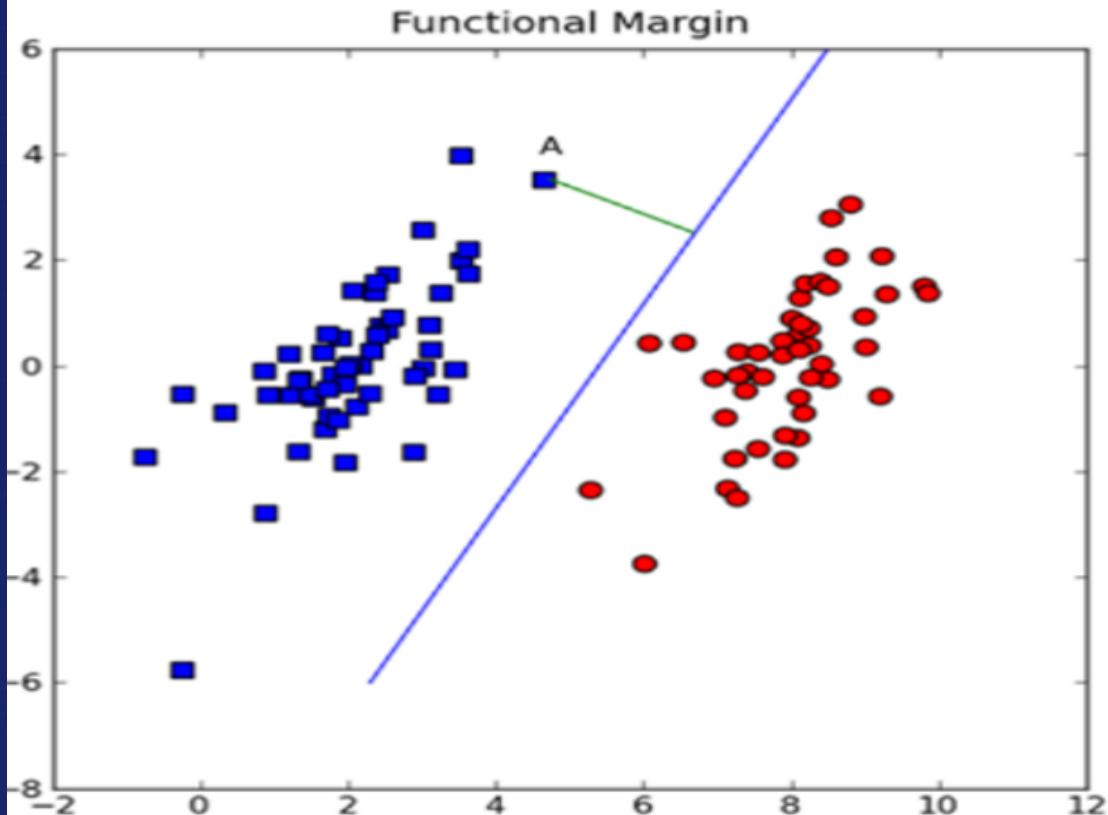


*Separating data with the maximum margin*



Variables independientes con dependientes



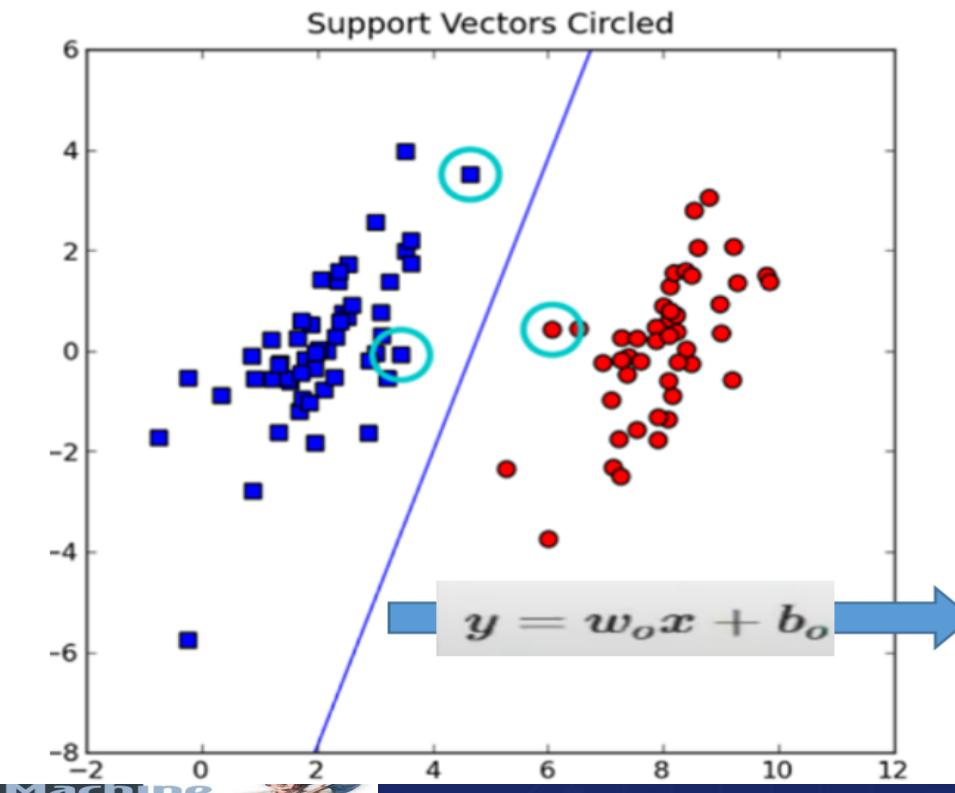


## *Separating data with the maximum margin*

La distancia desde el punto A hasta el plano de separación se mide por una línea normal, al plano de separación.



## Máquinas de Soporte Vectorial (SVM)



*Separating data with the maximum margin*

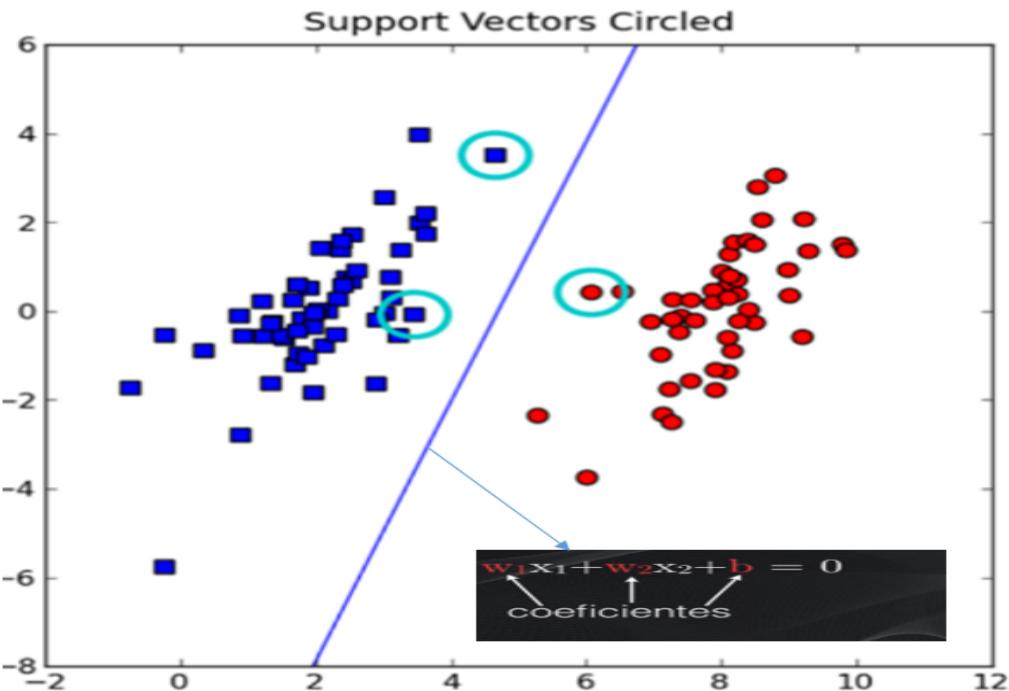
Conjunto de datos de muestra de mostrando los vectores de soporte rodeados por un círculo y el hiperplano de separación

El hiperplano es nuestro límite de decisión. Todo lo que está en un lado pertenece a una clase y todo del otro lado pertenece a una clase diferente.



UT TALENTOTECH

## Máquinas de Soporte Vectorial (SVM)



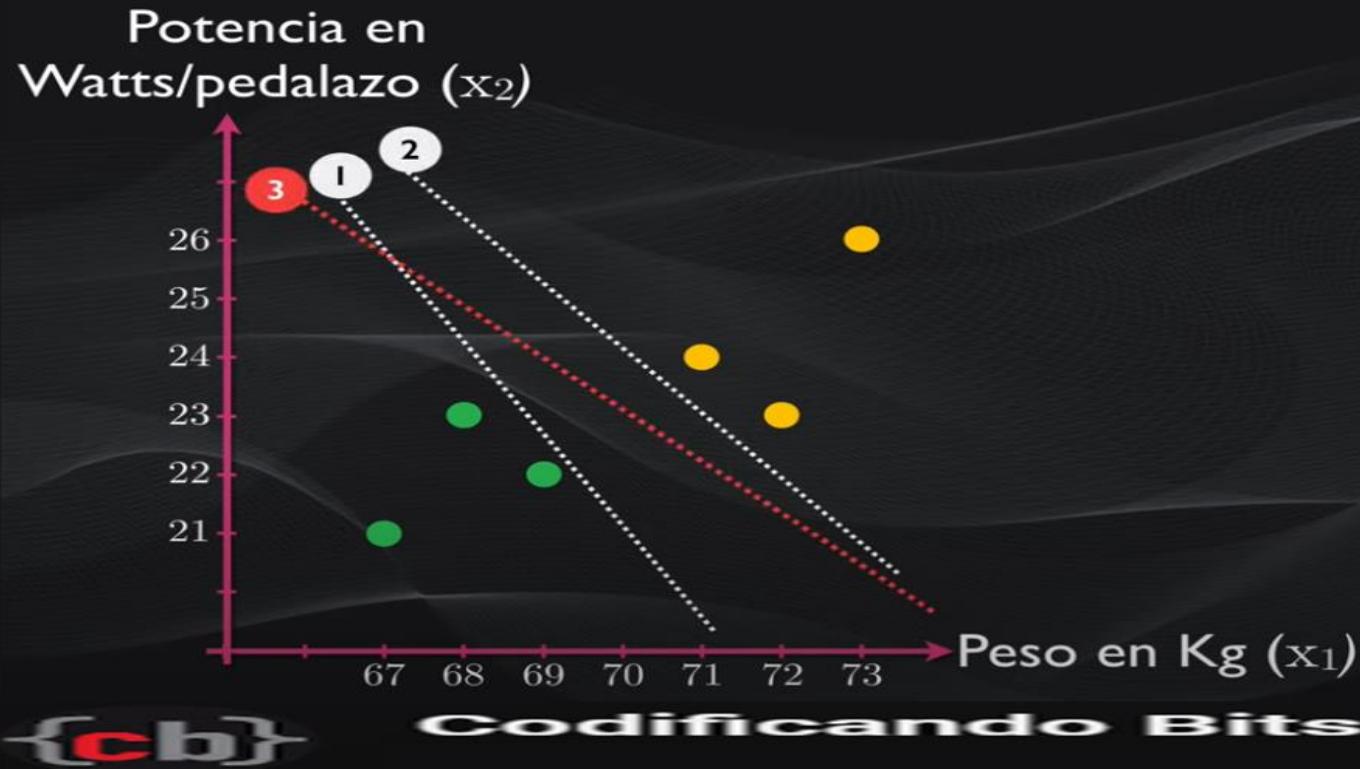
Los puntos más cercanos al hiperplano de separación se conocen como vectores de soporte.

Se trata de maximizar la distancia desde la línea de separación hasta los vectores de soporte, necesitamos encontrar una manera de optimizar este problema.



UT TALENTOTECH

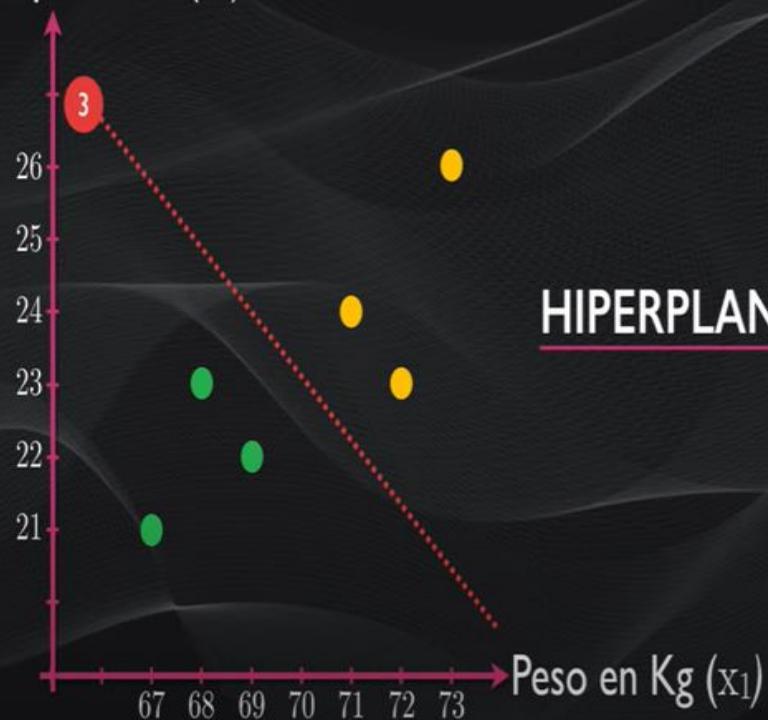
## Máquinas de Soporte Vectorial VM)



Cuál es el mejor Hiperplano?

## Máquinas de Soporte Vectorial (SVM)

Watts/pedalazo ( $x_2$ )



{cb}

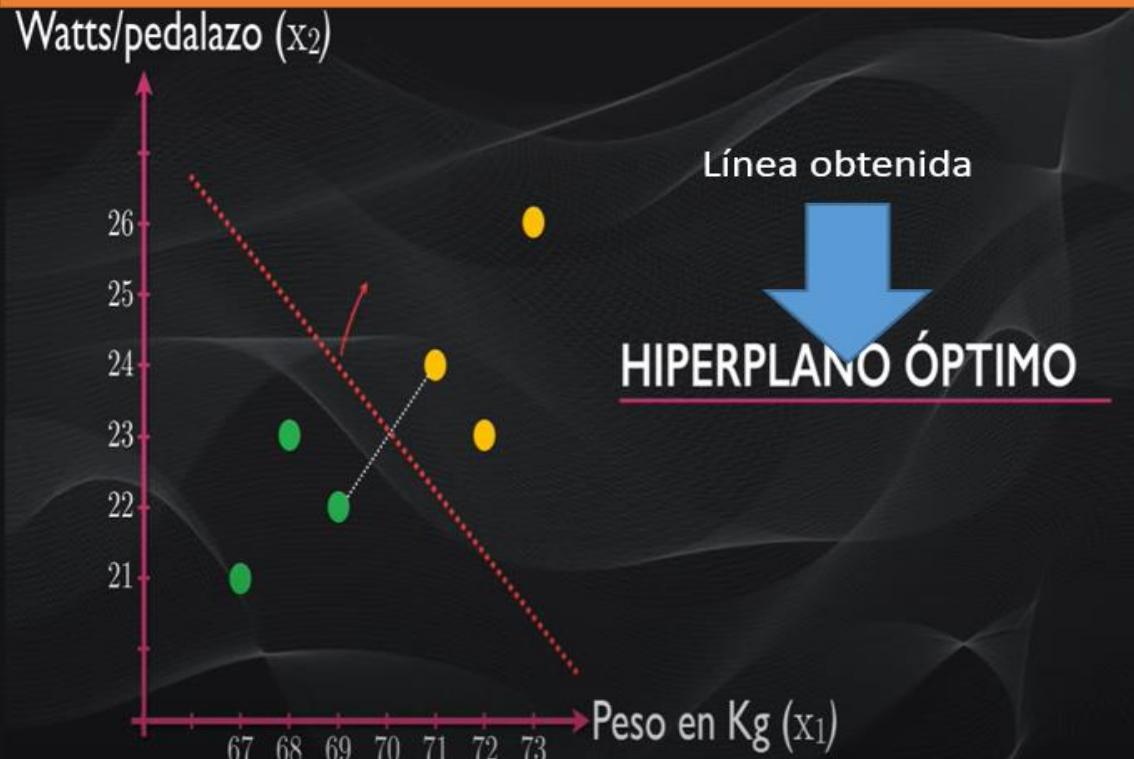
Codificando Bits

Cuál es el mejor Hiperplano?

La línea 3, está más alejada de las categorías y permite que no haya sesgo

**HIPERPLANO ÓPTIMO**

# Máquinas de Soporte Vectorial (SVM)



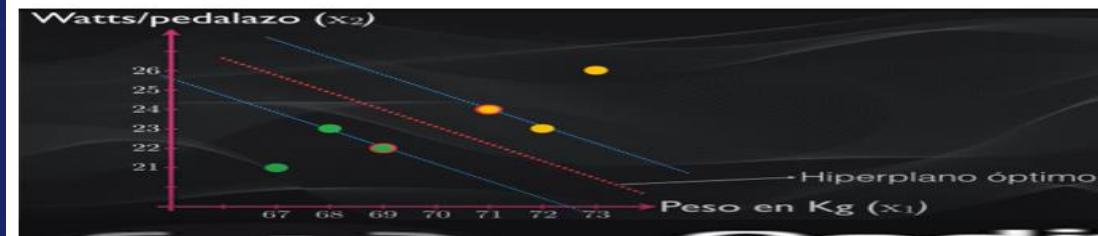
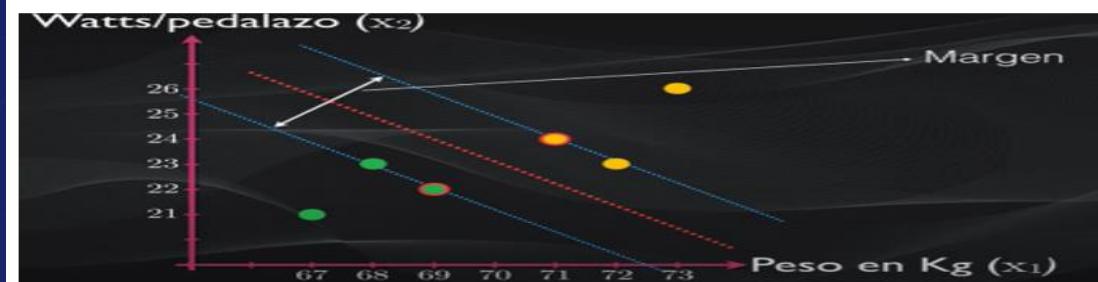
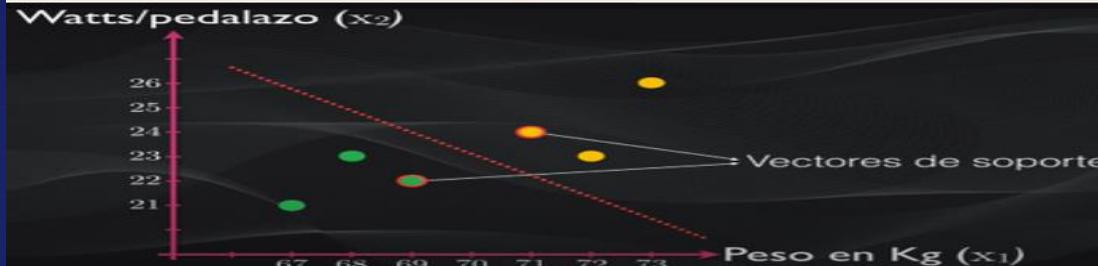
## HARD MARGIN

Se detectan los puntos más cercanos entre una clase y otra.

Encuentra la línea que los conecta

Traza una frontera perpendicular, que divide la línea en 2.

# Máquinas de Soporte Vectorial (SVM)



**Vectores de soporte.**

Puntos más cercanos entre una clase y otro.

**Margen**

Distancia entre el hiperplano y vectores de soporte.  
Toca al menos un punto de cada clase.

**Hiperplano óptimo**

Frontera con mayor margen posible

$w^T x + b.$



$$w_1x_1 + w_2x_2 + b = 0$$

↑                   ↑                   ↑  
coeficientes      coeficientes      coeficiente



## Máquinas de Soporte Vectorial (SVM)

$$\mathbf{w}^T \mathbf{x} + b.$$



$$w_1x_1 + w_2x_2 + b = 0$$

↑  
coeficientes

Si queremos encontrar el distancia de A al plano de separación, debemos medir normal o perpendicularmente la línea. Esto está dado por

$$| \mathbf{w}^T \mathbf{x} + b | / \| \mathbf{w} \|$$

## Máquinas de Soporte Vectorial (SVM)

El objetivo ahora es encontrar los valores de  $w$  y  $b$  que definirán el clasificador.

Se encontrarán los puntos con menor margen, estos son los vectores de soporte.

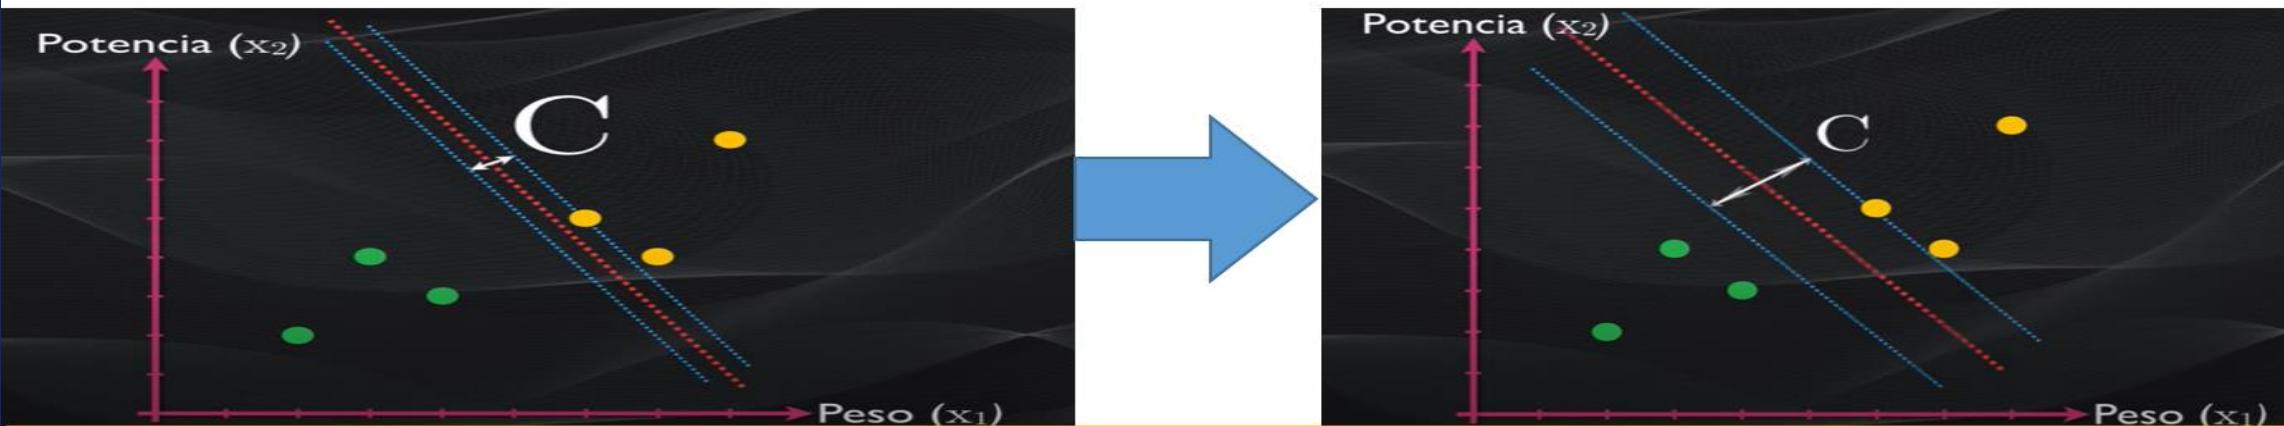
Cuando se encuentran los puntos con menor margen, se debe maximizar ese margen.

$$\arg \max_{w,b} \left\{ \min_n (\text{label} \cdot (w^T x + b)) \cdot \frac{1}{\|w\|} \right\}$$

# Máquinas de Soporte Vectorial (SVM)

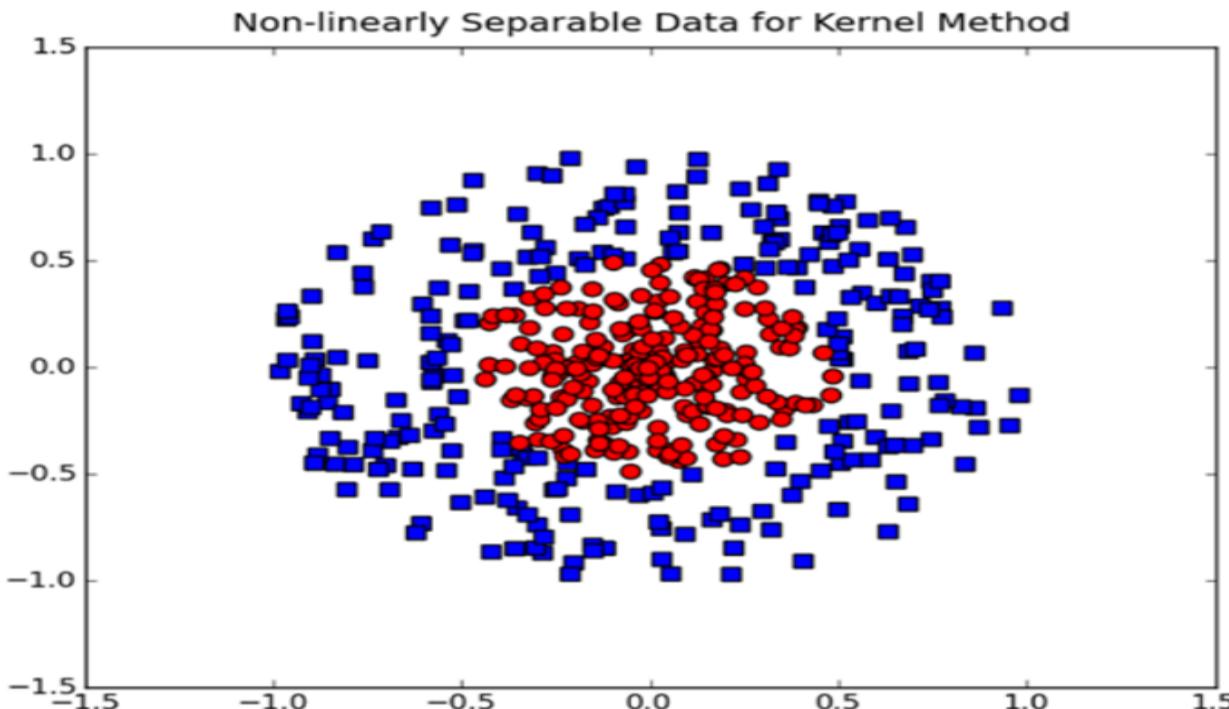
## Soft Margin

En ocasiones no es posible encontrar datos “perfectos”, en estos casos se utiliza un Hiperparámetro C, con el que podemos aumentar o disminuir el margen.



Si el tamaño aumenta, el margen se reduce. Se escoge por prueba y error.. (error)

# Máquinas de Soporte Vectorial (SVM)



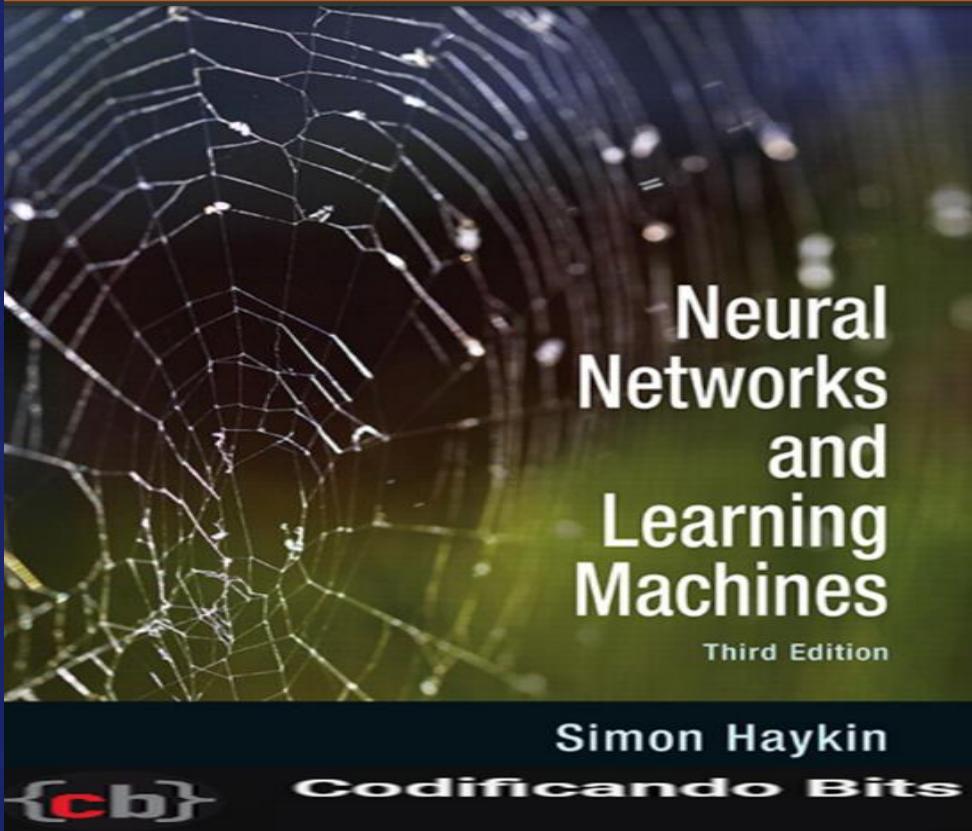
Qué pasa si los  
datos tienen otro  
comportamiento?



{cb}

Codificando Bits

## Máquinas de Soporte Vectorial (SVM)

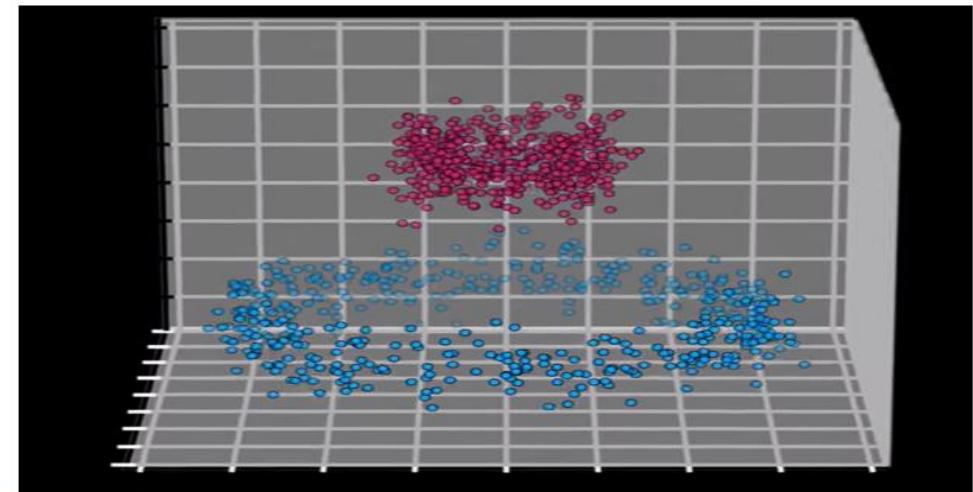
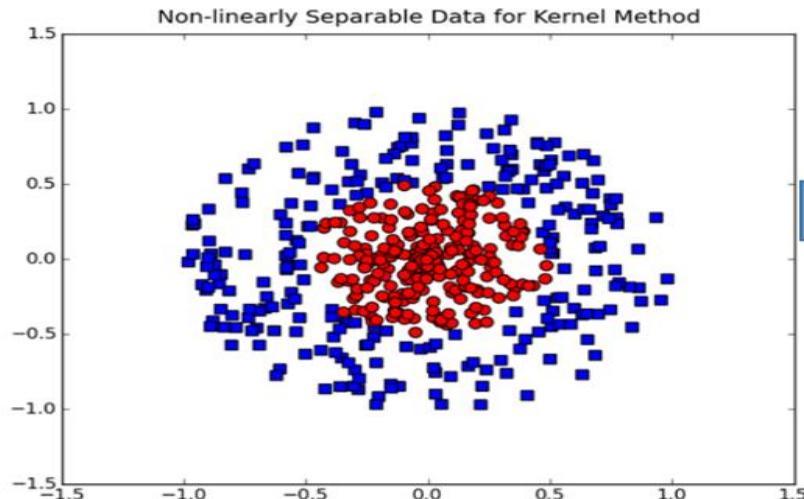


# Kernel

## The Kernel Trick

## Máquinas de Soporte Vectorial (SVM)

**Los datos se llevan a otra dimensión.**



**Se agregan más dimensiones a los datos.**



Codificando Bits

H



► TALENTO  
TECH



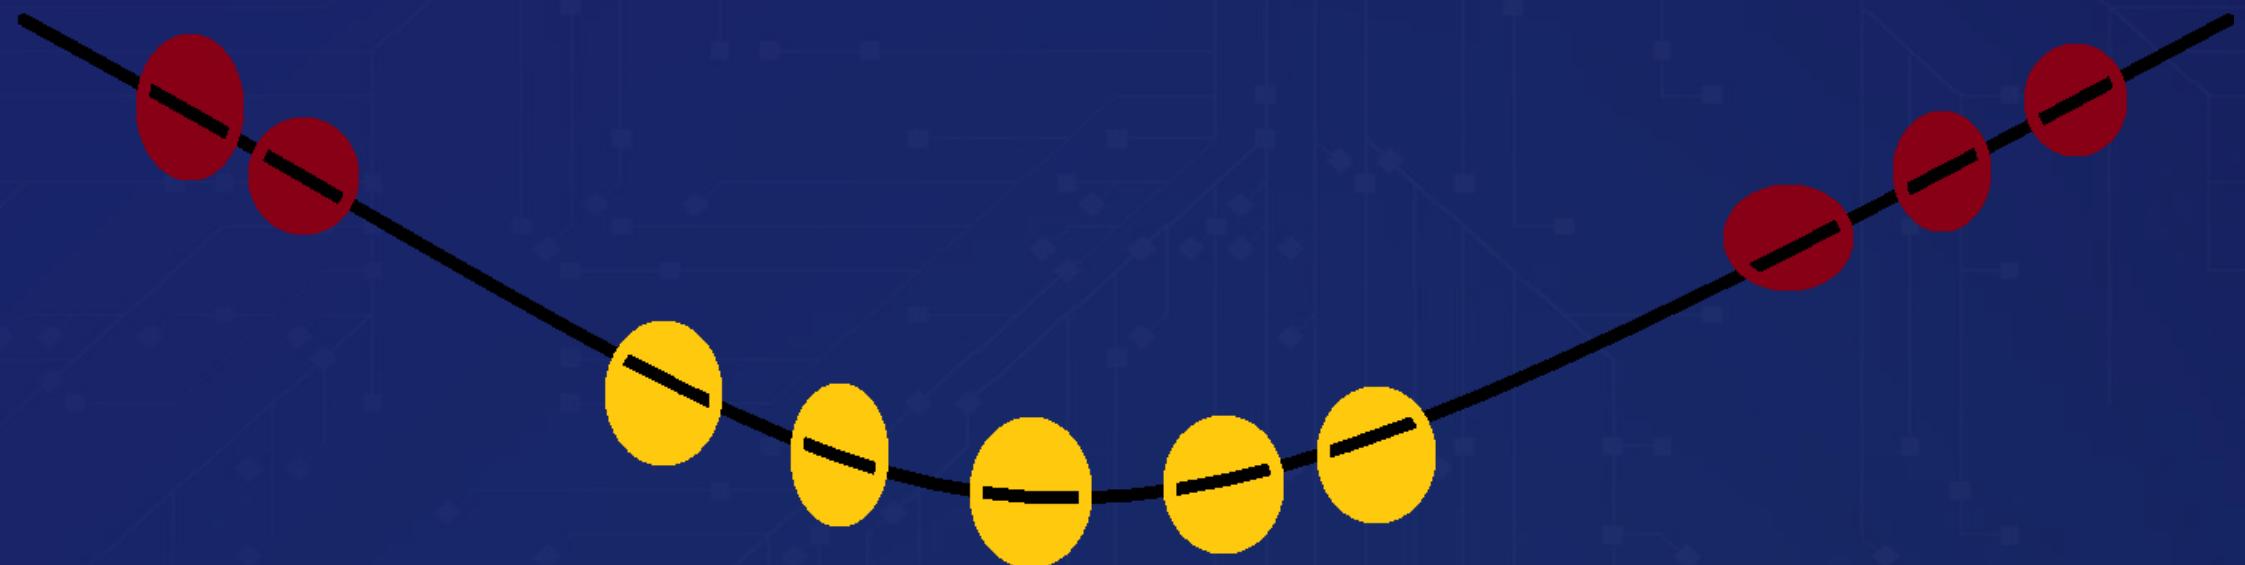
UT TALENTOTECH

Profesor: Víctor Viera Balanta





► TALENTO  
TECH



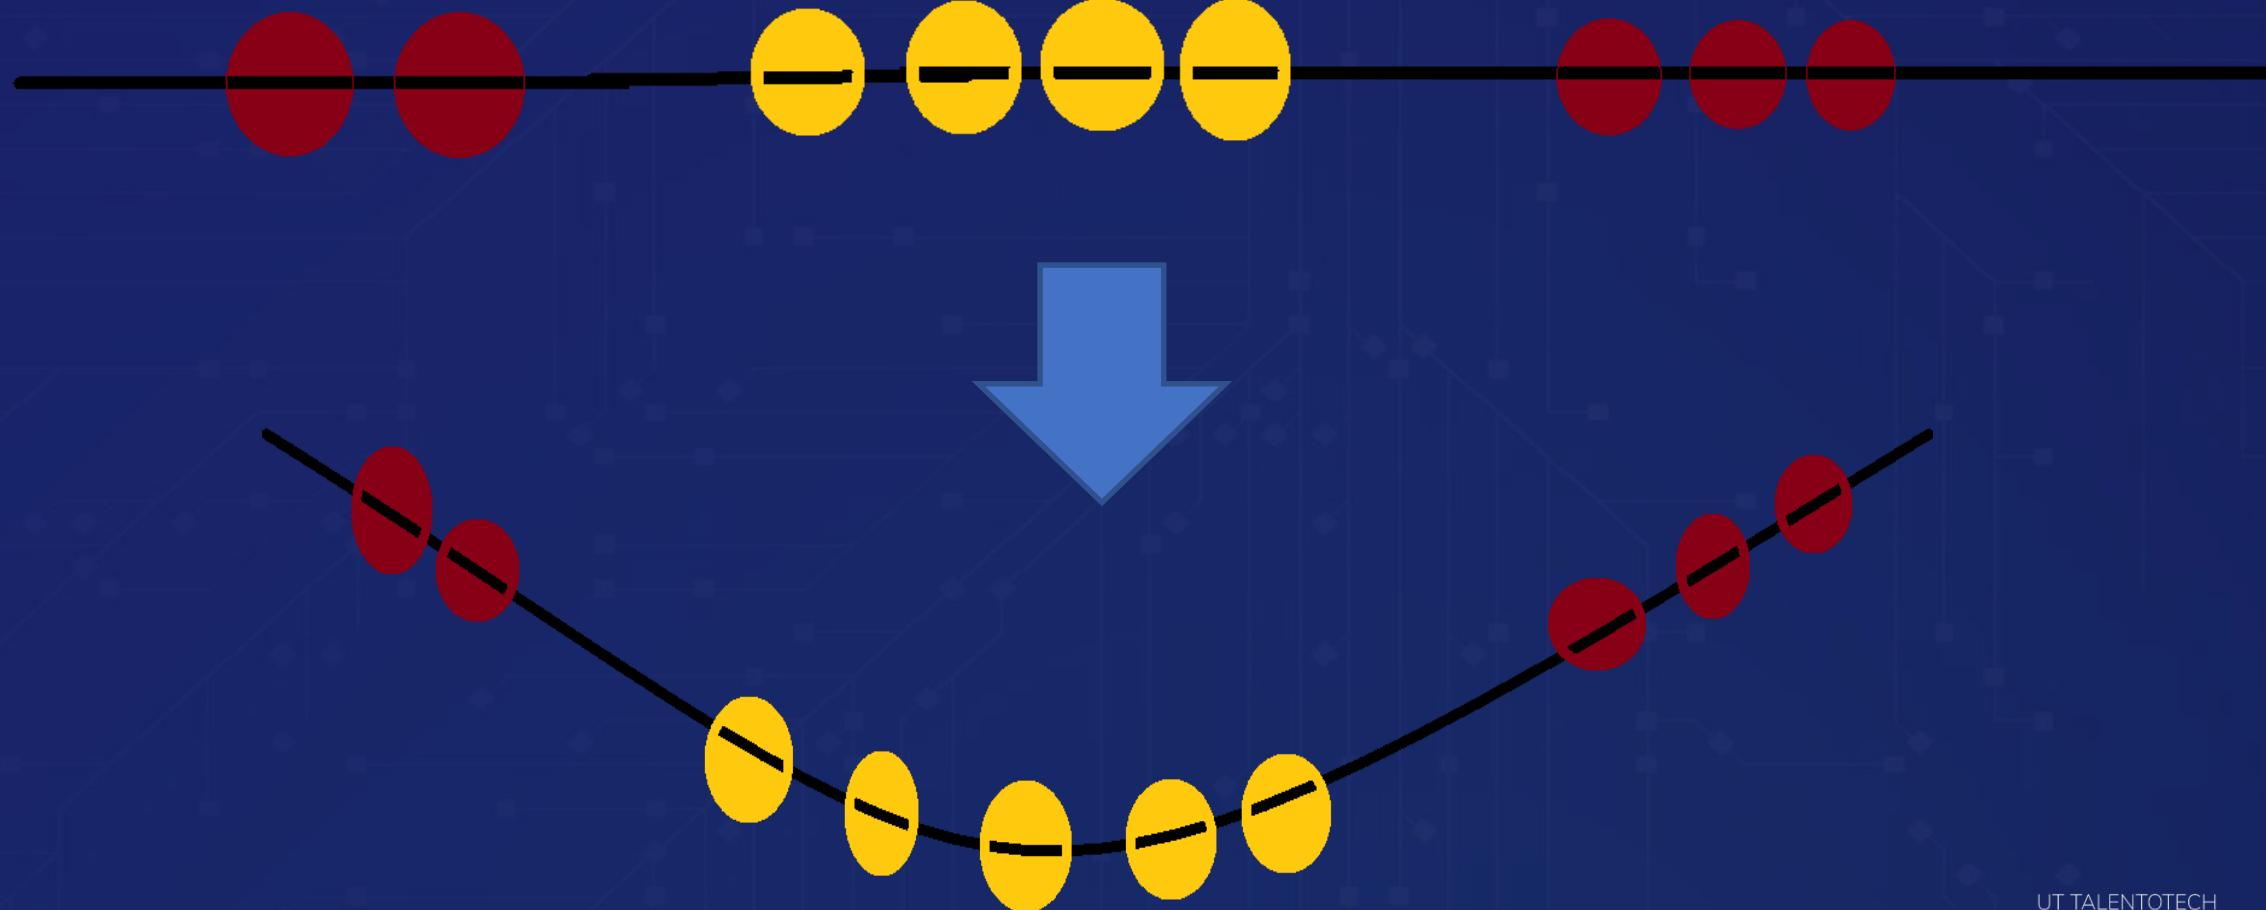
UT TALENTOTECH

Profesor: Víctor Viera Balanta

cymetria | tecnalia  
colombia



► TALENTO  
TECH



UT TALENTOTECH

Profesor: Víctor Viera Balanta

cymetria | tecnalia  
colombia

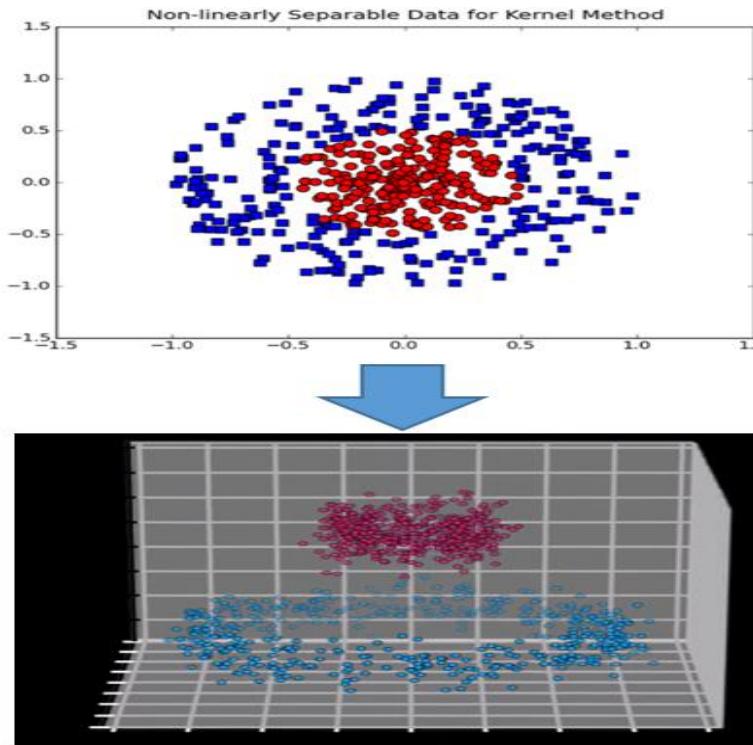


UT TALENTOTECH

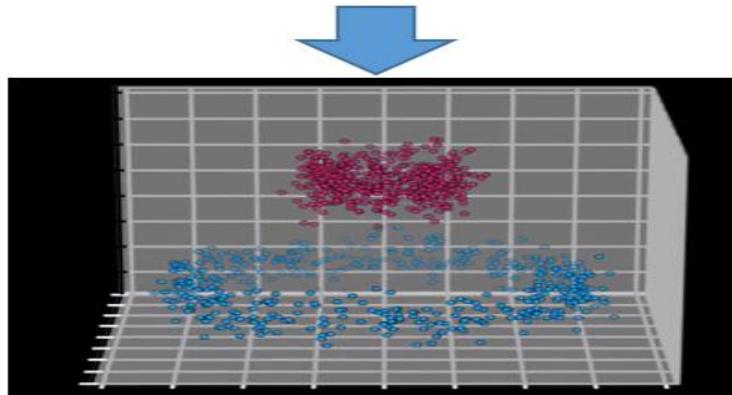
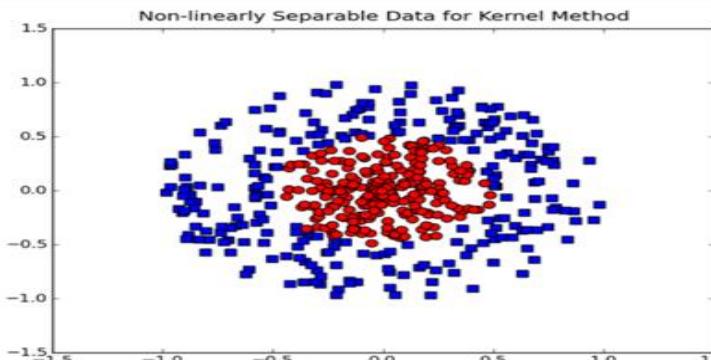
Profesor: Víctor Viera Balanta



# Máquinas de Soporte Vectorial (SVM)



# Máquinas de Soporte Vectorial (SVM)



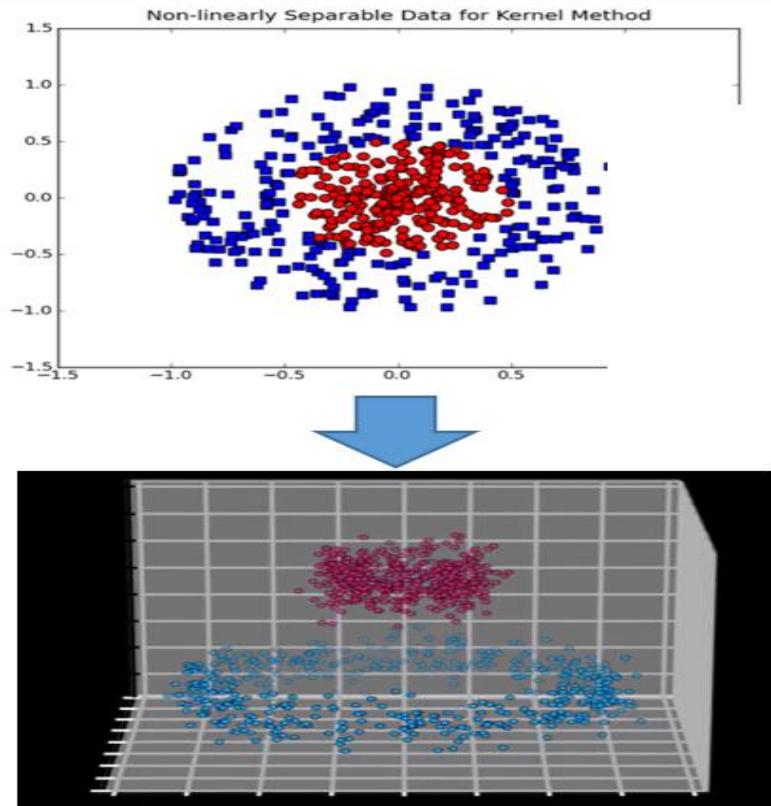
Funciones Kernel  
Polinomiales  
Gaussianas

$$k(x, y) = \exp\left(\frac{-\|x - y\|^2}{2\sigma^2}\right)$$

donde alpha es un parámetro definido por el usuario que determina el "alcance", o la rapidez con la que este cae a 0



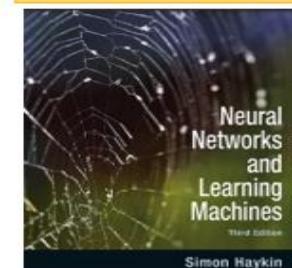
# Máquinas de Soporte Vectorial (SVM)



$$\mathcal{T} = \{\mathbf{x}_i, d_i\}_{i=1}^N$$

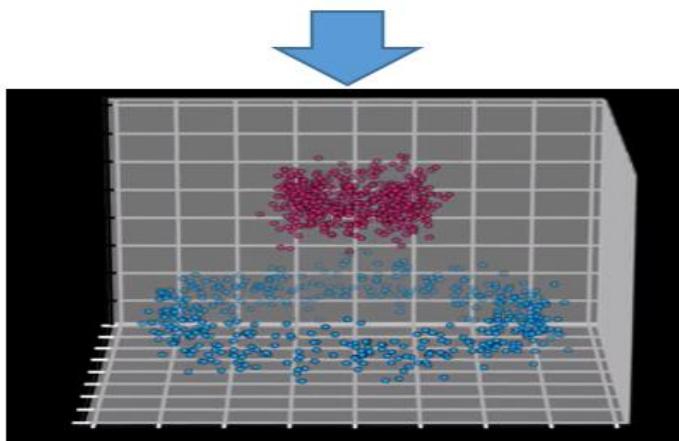
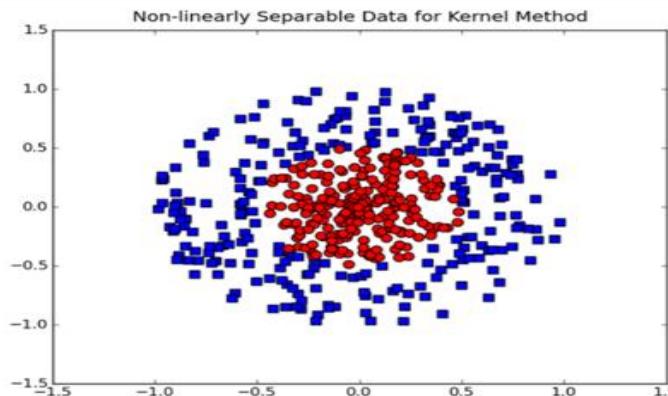
Datos Independientes

Etiquetas



UT TALENTOTECH

# Máquinas de Soporte Vectorial (SVM)



## Multiplicadores de Lagrange

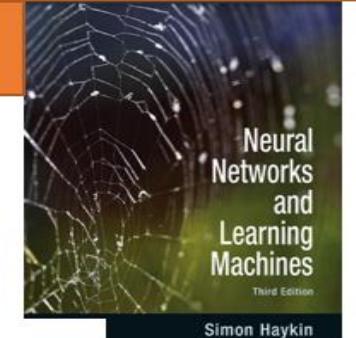
$$\mathcal{T} = \{\mathbf{x}_i, d_i\}_{i=1}^N$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, 2, \dots, N$$

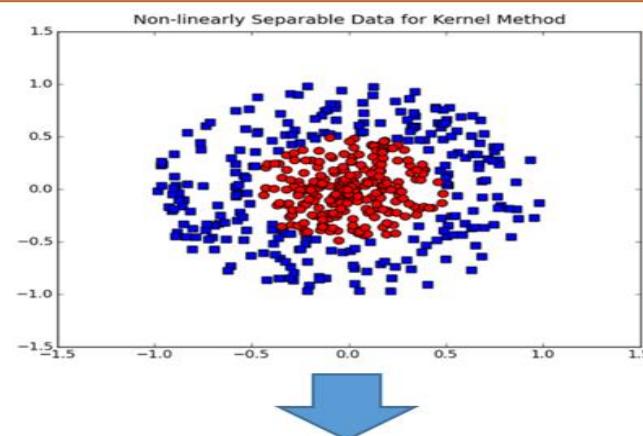
$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$>0$$

**Restricción:**  
La sumatoria de los multiplicadores de Lagrange por las etiquetas debe ser igual a cero



# Máquinas de Soporte Vectorial (SVM)



## Multiplicadores de Lagrange

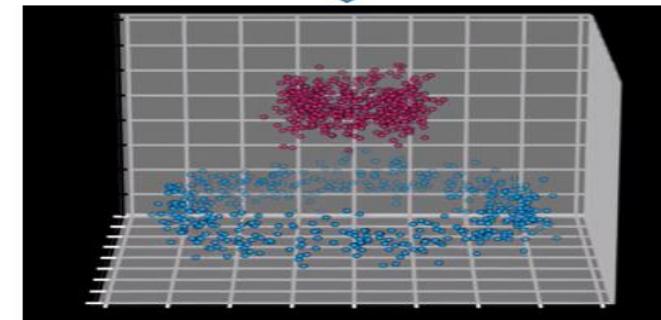
$$\mathcal{T} = \{\mathbf{x}_i, d_i\}_{i=1}^N$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, 2, \dots, N$$

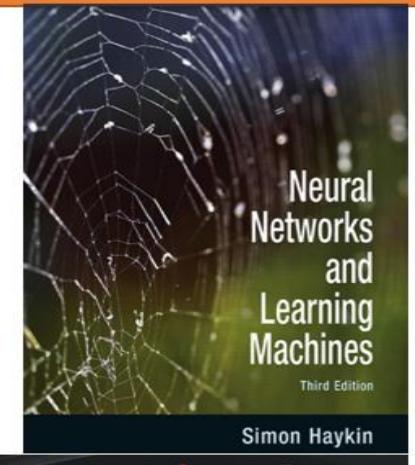
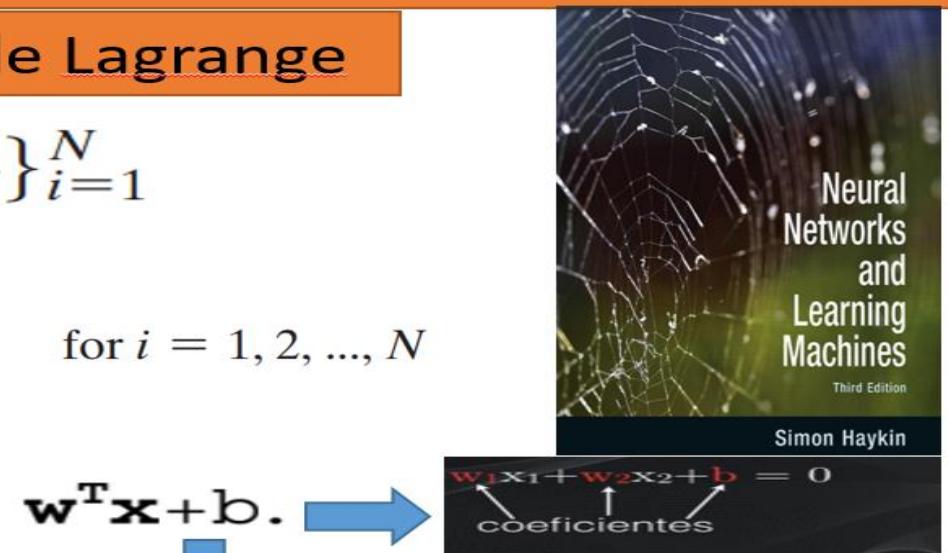
$$\sum_{i=1}^N \alpha_i d_i = 0$$

$$y = w_o \mathbf{x} + b_o$$

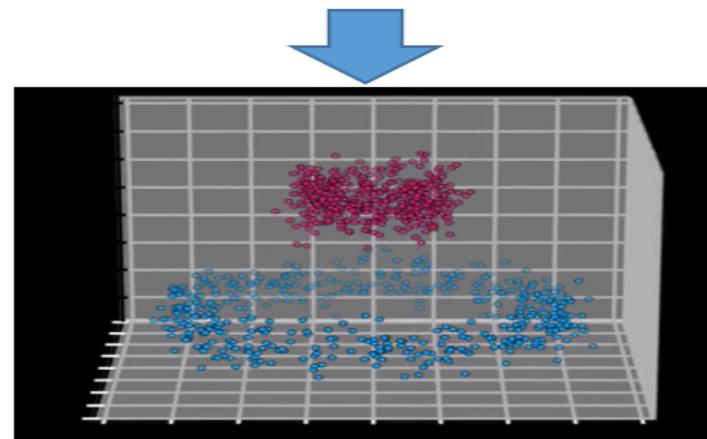
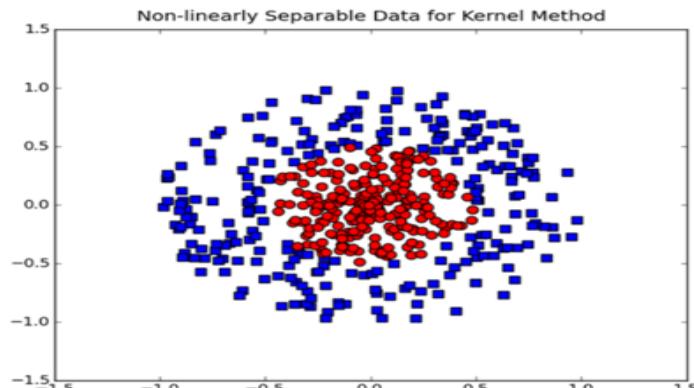
In this case,  $y$  can be  $+1$  (class 1) or  $-1$  (class 2).



<https://dai.fmph.uniba.sk/courses/NN/haykin.neural-networks.3ed.2009.pdf>



# Máquinas de Soporte Vectorial (SVM)



## Multiplicadores de Lagrange

$$\mathcal{T} = \{\mathbf{x}_i, d_i\}_{i=1}^N$$

$$d_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \text{for } i = 1, 2, \dots, N$$

$$(1) \quad \sum_{i=1}^N \alpha_i d_i = 0$$

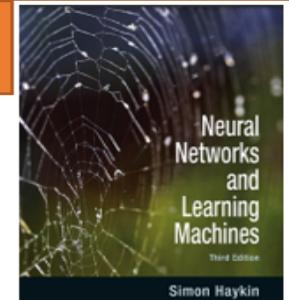
$$(2) \quad \alpha_i \geq 0 \quad \text{for } i = 1, 2, \dots, N$$

→ Restricciones

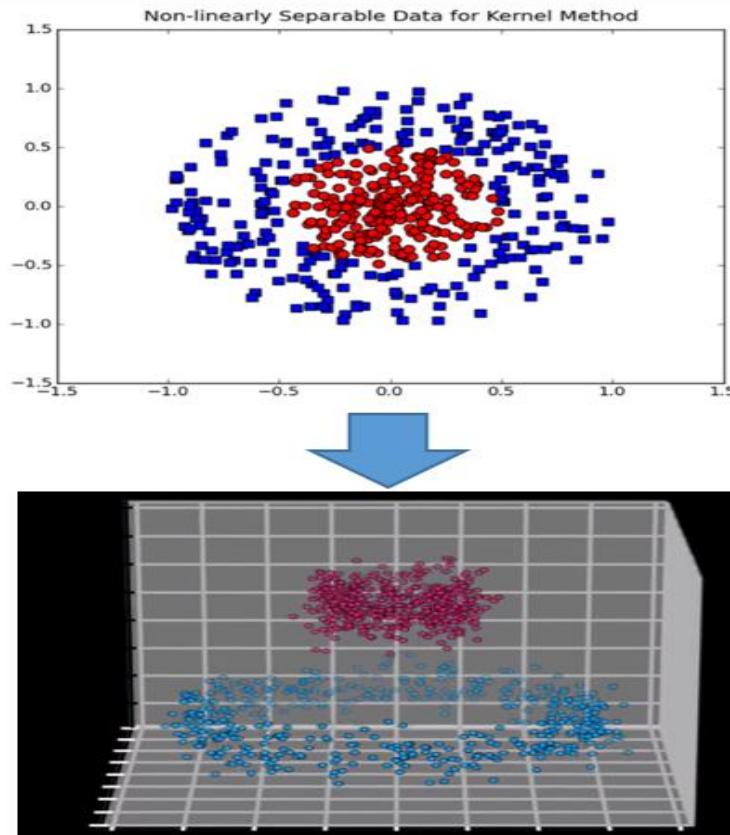
$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j \quad (6.16)$$

La función de costo depende: de los multiplicadores de Lagrange para cada punto, las etiquetas y los patrones (los Xs)

Maximizar la función de costo. Representación Dual



# Máquinas de Soporte Vectorial (SVM)



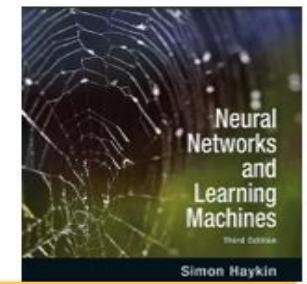
Multiplicadores de Lagrange

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j \mathbf{x}_i^T \mathbf{x}_j \quad (6.16)$$

$$Q(\alpha) = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j d_i d_j k(\mathbf{x}_i, \mathbf{x}_j) \quad (6.39)$$



Kernel





TIC

¡Gracias!

UT TALENTOTECH

